



清华大学

综合论文训练

数据驱动的宇宙学快速模拟方法

系 别： 致理书院

专 业： 数理基础科学

姓 名： 刘 以 恒

指导教师： 赵 成 副教授

二〇二六年六月

关于论文使用授权的说明

本人完全了解清华大学有关保留、使用综合论文训练论文的规定，即：学校有权保留论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

作者签名：刘以恒

日期：2026.6.22

导师签名：

日期：2026.6.22

摘 要

大尺度结构观测中的宇宙学参数推断通常需要大量模拟样本来估计协方差矩阵，并要求模拟能够同时给出可靠的暗物质密度场和速度场。传统 N 体模拟具有较高精度，但计算代价高昂；基于拉格朗日微扰论的快速模拟方法效率较高，却难以准确刻画非线性小尺度结构及速度场细节。针对这一问题，本文提出一种数据驱动的宇宙学快速模拟流程：首先以 Zel'dovich 近似 (ZA) 生成位移场和速度场的大尺度基准，再分别训练两个三维生成对抗网络学习位移残差和速度残差。其中，位移网络以 ZA 位移场为条件输入；速度网络以 ZA 速度场和位移网络推理得到的最终位移场为联合条件输入，从而利用已恢复的非线性结构信息进一步修正速度场。网络采用三维 U 形生成器与多尺度判别器，并在推理阶段结合分块推理、高通滤波和旋转平均等策略，使该流程在保持快速生成优势的同时，能够稳定扩展至同分辨率下更大体积的模拟任务。

本文基于 Quijote N 体模拟对所提出流程进行了验证。结果表明，与 ZA、2LPT 和 ALPT 等微扰论方法相比，本文方法生成的暗物质密度场在切片形态、概率密度函数、功率谱、双谱和功率谱协方差矩阵等统计量上均更接近 N 体参考结果，能够有效恢复小尺度非线性功率和高阶关联。在速度场方面，本文方法相较 ZA 在速度模切片、速度散度功率谱以及各速度分量功率谱上均有明显改进，对旋度以及维里化区域中的小尺度随机速度也有一定恢复。总体而言，本文方法在保持大尺度结构一致性的同时，改善了密度场和速度场的小尺度统计性质，为面向多探针宇宙学分析的快速模拟提供了一种可行方案。

关键词：宇宙学快速模拟； N 体模拟；生成对抗网络；暗物质密度场；速度场

Abstract

Cosmological parameter inference from large-scale structure observations generally requires a large number of simulation realizations for covariance-matrix estimation, and these simulations should provide reliable dark matter density and velocity fields at the same time. Full N-body simulations are accurate but computationally expensive. Fast simulation methods based on Lagrangian perturbation theory are much more efficient, but they cannot accurately describe nonlinear small-scale structures or detailed velocity-field features. To address this problem, this thesis proposes a data-driven fast cosmological simulation pipeline. The pipeline first uses the Zel’dovich approximation (ZA) to generate large-scale reference fields for displacement and velocity, and then trains two three-dimensional generative adversarial networks to learn the corresponding displacement and velocity residuals. The displacement network takes the ZA displacement field as its conditional input. The velocity network is conditioned jointly on the ZA velocity field and the final displacement field inferred by the displacement network, so that the recovered nonlinear structural information can be used to further correct the velocity field. The networks adopt three-dimensional U-shaped generators and multi-scale discriminators. At the inference stage, tiled inference, high-pass filtering, and rotation averaging are combined, enabling the pipeline to scale stably to larger simulation volumes at the same resolution while preserving the advantage of fast generation.

The proposed pipeline is validated using Quijote N-body simulations. The results show that, compared with perturbative methods such as ZA, 2LPT, and ALPT, the dark matter density fields generated by the proposed method are closer to the N-body reference in slice morphology, probability density functions, power spectra, bispectra, and power-spectrum covariance matrices. The method therefore effectively recovers nonlinear small-scale power and higher-order correlations. For the velocity field, the proposed method achieves clear improvements over ZA in velocity-magnitude slices, velocity-divergence power spectra, and power spectra of individual velocity components. It also provides partial recovery of vorticity and small-scale stochastic velocities in virialized regions. Overall, the proposed method improves the small-scale statistical properties of both density and velocity fields while maintaining consistency on large scales, providing a feasible fast-simulation approach for multi-probe cosmological analyses.

Keywords: fast cosmological simulation; N-body simulation; generative adversarial network; dark matter density field; velocity field

目 录

第 1 章 引 言.....	1
1.1 宇宙学分析的方法与手段	1
1.1.1 协方差矩阵与 N 体模拟	1
1.2 宇宙学快速模拟方法	2
1.2.1 宇宙学快速模拟方法的需求	2
1.2.2 宇宙学快速模拟方法的研究现状与不足	2
1.2.3 本文研究内容与贡献	3
1.3 文章结构	4
第 2 章 方 法.....	5
2.1 工作流总述	5
2.2 模拟参考样本概述	6
2.3 大尺度结构生成	6
2.4 小尺度结构纠偏	7
2.4.1 网络架构	7
2.4.2 损失函数	11
2.4.3 模型训练	12
2.4.4 模型推理	12
第 3 章 研究成果.....	14
3.1 暗物质场单点统计	14
3.2 暗物质场两点统计	15
3.3 暗物质场三点统计	16
3.4 暗物质功率谱协方差矩阵	17
3.5 速度场视觉展示	18
3.6 速度场两点统计	19
3.7 运行时间与内存占用	20
第 4 章 结论与展望.....	22
参考文献.....	23
致 谢.....	25
声 明.....	26

插图清单

图 2.1 工作流示意图.....	6
图 2.2 残差网络结构.....	9
图 3.1 过密度切片比较.....	14
图 3.2 过密度残差概率密度函数比较.....	15
图 3.3 暗物质功率谱比值.....	16
图 3.4 暗物质双谱比值.....	17
图 3.5 暗物质功率谱协方差矩阵.....	18
图 3.6 速度模切片比较.....	19
图 3.7 速度场功率谱比值.....	20

附表清单

表 3.1 运行时间与内存占用.....	21
----------------------	----

符号和缩略语说明

ALPT	增强拉格朗日微扰论 (Augmented Lagrangian Perturbation Theory)
CMB	宇宙微波背景辐射 (Cosmic Microwave Background)
CSST	中国空间站望远镜 (Chinese Space Station Telescope)
DESI	暗能量光谱巡天 (Dark Energy Spectroscopic Instrument)
DR	数据发布 (Data Release)
GAN	生成对抗网络 (Generative Adversarial Network)
PDF	概率分布函数 (Probability Density Function)
SDSS	斯隆数字巡天 (Sloan Digital Sky Survey)
SZ 效应	Sunyaev-Zel'dovich 效应
WGAN-GP	带梯度惩罚的 Wasserstein 生成对抗网络 (Wasserstein GAN with Gradient Penalty)
ZA	Zel'dovich 近似
2LPT	二阶拉格朗日微扰论 (Second-order Lagrangian Perturbation Theory)
Λ CDM	冷暗物质模型 (Lambda Cold Dark Matter)
δ	暗物质过密度场
ρ	暗物质密度
$\bar{\rho}$	平均暗物质密度
Ψ	粒子位移场
$\mathbf{v}$	粒子速度场
$D(z)$	线性增长因子
$f(z)$	线性增长率
$H(z)$	红移 z 处的哈勃参数
h	无量纲哈勃参数
$P(k)$	暗物质功率谱
$B(k_1, k_2, k_3)$	暗物质双谱

第 1 章 引 言

1.1 宇宙学分析的方法与手段

现代宇宙学的一个核心目标，是利用观测数据精确测量宇宙学参数，并由此检验宇宙的组成、几何结构和演化历史。不同观测探针从不同角度提供信息：星系巡天项目（如 DESI、SDSS）通过测量星系光谱，重建星系在三维空间中的分布，并利用星系成团性约束宇宙学模型^[1]；引力透镜观测则利用宇宙微波背景辐射的透镜畸变（CMB 透镜，如 Planck 卫星项目）或星系形态在引力场中的微弱畸变（弱引力透镜，如 Euclid、CSST 项目），反推出宇宙中的物质分布^[2-4]；超新星作为标准烛光，其光变曲线和亮度距离关系也可用于限制宇宙膨胀历史。

这些探针虽然观测对象和数据形式不同，但在参数推断中通常遵循相近的贝叶斯分析框架。具体而言，观测数据首先被压缩为功率谱、关联函数、距离模数等数据向量；随后，在给定宇宙学模型和模型参数的条件下，计算相应的理论预期以及数据向量的误差分布。通过比较观测数据与理论预期，并在参数空间中采样，即可得到宇宙学参数的后验概率分布。在这一过程中，协方差矩阵决定了不同数据分量的误差大小及其相关性，是连接观测数据与参数约束的重要桥梁。

1.1.1 协方差矩阵与 N 体模拟

协方差矩阵描述数据向量在重复观测之间的涨落，通常包含统计误差和系统误差两类来源。对于理想化情形，协方差矩阵有时可以通过解析方法计算；但在真实巡天中，观测几何、选择函数、非线性引力演化以及示踪天体形成机制都会显著增加问题复杂度，使得解析表达式难以准确获得。因此，在星系巡天、弱引力透镜等低红移探针的分析中，协方差矩阵往往需要依赖大量数值模拟进行估计。

目前，宇宙学模拟中最常用也最可靠的基准方法是 N 体模拟。在冷暗物质模型假设下，N 体模拟先根据给定宇宙学参数生成初始时刻的暗物质粒子分布，再通过粒子之间的引力相互作用演化系统，最终得到目标红移处暗物质粒子的位置和速度^[5]。对于星系巡天、弱引力透镜等具体探针，还需要在暗物质场的基础上进一步构造相应的示踪天体分布。

即使宇宙学参数完全相同，不同模拟实现也会因为初始随机种子不同而产生不同的粒子初始位置。这些初始涨落经过非线性引力演化后，会导致最终的暗物质密度场、速度场以及示踪天体分布产生差异，并进一步表现为数据向量的统计涨落。因此，使用一组相互独立的模拟实现估计数据向量的样本协方差，是宇宙

学参数推断中的常见做法。至于仪器标定、观测选择效应等系统误差，也可以在部分情况下通过模拟流程建模，但这并非本文的讨论重点。

1.2 宇宙学快速模拟方法

高精度 N 体模拟能够较准确地刻画暗物质结构的非线性演化，但其计算代价也十分高昂。为了达到现代宇宙学测量所需的体积和分辨率，单个模拟往往需要 Gpc 尺度为边长的模拟盒子以及数亿乃至数十亿个粒子。如此大规模的粒子体系在相互引力作用下演化，通常需要数天到数月的计算时间；而协方差矩阵估计又往往需要上千个相互独立的模拟实现。由此可见，仅依赖完整 N 体模拟难以满足大规模误差估计的需求，发展计算效率更高的宇宙学快速模拟方法具有重要意义。

1.2.1 宇宙学快速模拟方法的需求

随着观测设备不断迭代，新一代巡天项目对快速模拟提出了更高的要求。首先，巡天体积持续增大，模拟需要覆盖更大的宇宙空间并处理更多暗物质粒子；其次，多探针联合分析正在成为提高宇宙学参数约束能力的重要方向，而不同探针之间的相关性只有在同一组模拟实现中才能被一致地估计。因此，面向未来巡天的快速模拟方法不能只服务于单一统计量，而应尽可能同时满足多类探针的需求。

具体而言，理想的快速模拟方法应具备以下特征：

- 生成速度快，能够在短时间内产生大量用于误差估计的模拟实现；
- 可扩展性强，在模拟体积增大或粒子数增加时仍能保持较高效率；
- 能够同时提供可靠的暗物质密度场和速度场，在大尺度上保持与 N 体模拟一致，并尽可能恢复小尺度非线性结构。

其中，星系巡天通常更关注大尺度成团性信息，而 CMB 透镜和弱引力透镜对小尺度物质分布也较为敏感；速度场则与红移空间畸变、运动学 SZ 效应等探针密切相关。因此，能够同时生成密度场和速度场的快速模拟方法，更适合服务于多探针联合分析。

1.2.2 宇宙学快速模拟方法的研究现状与不足

传统快速模拟方法大多从拉格朗日微扰论出发。拉格朗日微扰论从粒子初始位置出发，通过微扰展开近似求解粒子在引力演化中的位移。例如， DESI DR1 中使用的 EZMock 方法基于 Zel'dovich 近似 (ZA ，即一阶拉格朗日微扰论)；而 DESI DR2 计划采用的模拟则基于增强拉格朗日微扰论 (ALPT)，该方法建立在二阶拉格朗日微扰论 (2LPT) 的基础之上^[6-8]。

微扰论的优点在于物理图像清晰、实现简单且计算速度较快。在大尺度上，由于密度涨落较小，引力演化接近线性，因此该方法能较好地保留大尺度结构信息。然而在引力演化后期，小尺度结构已进入强非线性区域，微扰展开难以准确描述诸如团块形成、丝状结构收缩以及空洞边界演化等过程。此时，近似轨迹容易发生“壳层穿越”现象，即不同粒子的预测轨迹相互交叉，而方法本身无法进一步描述维里化与绕转运动，导致小尺度结构被过度平滑。尽管结合偏置模型或经验修正后，这类方法能够满足部分当前星系巡天分析的需求，但面对下一代探针对小尺度非线性结构的精度要求，其能力仍然不足。

除拉格朗日微扰论外，也可在欧拉空间中直接研究固定位置上的密度场与速度场演化^[9,10]。然而，将欧拉空间微扰理论直接应用于快速模拟时，强非线性区域中的微扰条件会被破坏，甚至出现负密度等非物理结果。基于有效场论的暗物质或星系分布模拟能够在一定程度上吸收小尺度物理的影响，但通常需要拟合额外的自由参数，且计算效率仍难以满足大批量协方差估计的需求^[11]。

近年来，机器学习方法为宇宙学快速模拟提供了新的方向。随着神经网络和生成模型的发展，已有研究尝试使用机器学习从近似初始条件或低精度结果中生成更接近 N 体模拟的暗物质场^[12-15]。其中，U 型网络能够同时利用全局上下文和局部细节，在三维场生成任务中具有较强表达能力。已有工作尝试使用 U 型网络架构预测任意红移下暗物质粒子的位移场和动量场，TUNeS 也采用类似思路预测任意红移下的物质密度场^[16]。不过，这些方法通常面对较高粒子分辨率下的复杂学习任务，训练难度较大；同时，许多方法未能同时给出可靠的粒子速度场，而速度场正是红移空间畸变、运动学 SZ 效应等探针模拟中不可或缺的物理量。

1.2.3 本文研究内容与贡献

针对上述问题，本文提出一种基于尺度分离思想的宇宙学快速模拟方法。该方法首先利用 ZA 快速生成位移场和速度场的大尺度基准；随后，通过两个独立的 WGAN-GP 残差网络分别学习 N 体模拟相对 ZA 的位移残差和速度残差，以补全非线性引力演化带来的小尺度结构细节。换言之，ZA 负责保留可靠的大尺度模式，神经网络则主要学习小尺度非线性修正，从而在降低学习难度的同时提高生成结果的物理一致性。

本文工作的主要贡献如下：

- 同时生成暗物质密度场和速度场：位移场可进一步构造密度场并服务于弱引力透镜等探针，速度场可服务于红移空间畸变、运动学 SZ 效应等探针，两者结合有助于多探针联合分析；
- 采用残差学习策略，将大尺度线性结构交由 ZA 描述，使神经网络专注于学

习小尺度非线性修正，降低了训练任务复杂度；

- 结合分块推理、高通滤波和旋转平均等策略，使模型在保持快速生成优势的同时，能够自然地扩展到大体积的模拟；
- 从单点统计、两点统计（功率谱）、三点统计（双谱）和协方差矩阵等多个角度验证方法效果，系统评估其相对于传统微扰论快速模拟的改进。

1.3 文章结构

本论文后续章节安排如下：第 2 章介绍本文提出的快速模拟方法，包括整体流程、ZA 大尺度结构生成、位移场与速度场残差网络、损失函数以及训练和推理细节；第 3 章展示研究成果，从暗物质密度场、速度场和协方差矩阵等方面评估所提方法的性能；第 4 章总结全文工作，并讨论后续可能的改进方向。

第 2 章 方 法

2.1 工作流总述

本文工作流采用尺度分离的思想：在大尺度上，微扰论仍然适用，因此使用 Zel'dovich 近似 (ZA) 提供位移场和速度场的大尺度信息；在小尺度上，引力非线性效应显著，因此通过神经网络学习目标结果与大尺度结果之间的残差，用于补全小尺度结构。

第一步，使用 ZA 生成大尺度结构。ZA 是拉格朗日微扰论的一阶近似，通过输入线性功率谱和宇宙学参数，可简单、快速地计算出每个粒子的位移和速度。它可以满足大尺度上位移场和速度场的准确性，但对于小尺度物理表现不佳。

第二步，使用 WGAN-GP 神经网络进行纠偏。考虑到显存限制、推理速度要求以及模拟需扩展到大体积的需求，我们将整个模拟盒子切割成小块，训练神经网络学习从 ZA 基准位移场到 N 体位移残差的映射。对于速度场，使用另一个 WGAN-GP 神经网络，输入为 ZA 基准速度场与位移推理结果的结合，输出为速度残差。这样，网络可同时利用速度场的线性大尺度信息和位移场中已恢复的非线性结构信息，更准确地补全小尺度速度结构。值得注意的是，在最小的尺度上，由于维里化效应，N 体模拟中的粒子位置和速度具有较强随机性，因此我们不要求神经网络完全恢复每个粒子的位移和速度，而是让网络在统计意义上尽可能接近 N 体结果的残差分布，从而补全小尺度结构的统计特征。

推理阶段，将 ZA 基准位移场切块后输入网络，得到残差预测，再将残差重新组合成大体积结果。对推理得到的位移残差场施加高通滤波，再与 ZA 位移场相加作为最终位移场输出，以减小从小体积拼接回大体积时产生的大尺度不稳定性，最后将该位移场赋给每个粒子得到粒子位移。速度场采用相同的切块和回填方式，但神经网络输入不再是单独的 ZA 速度场，而是 ZA 基准速度场与上一步推理得到的最终位移场的结合，输出则为速度残差。由于 ZA 速度场在大尺度上不如位移场可靠，当前推理阶段不对速度残差施加高通滤波，而是直接与 ZA 基准速度场相加得到最终速度场。

整体流程如图 2.1 所示。




图 2.1 工作流程示意图

2.2 模拟参考样本概述

为验证工作流的可行性，实验中使用 Quijote N 体模拟数据集作为参考样本^[17]。每个模拟盒子体积为 $1 (h^{-1}\text{Gpc})^3$ ，粒子数为 256^3 ，对应平坦 ΛCDM 宇宙学，宇宙学参数为 $\Omega_b = 0$ 、 $\Omega_m = 0.3175$ 、 $h = 0.6711$ 、 $\sigma_8 = 0.834$ 、 $A_s = 2.13 \times 10^{-9}$ 、 $n_s = 0.9624$ 。其中 Ω_b 和 Ω_m 分别为重子物质与总物质密度参数， h 为无量纲哈勃常数， σ_8 为 $8 h^{-1}\text{Mpc}$ 尺度上的线性密度扰动均方根， A_s 为原初标量扰动振幅， n_s 为原初标量谱指数。

2.3 大尺度结构生成

我们使用 ZA 作为大尺度基准。粒子采样位置 $\mathbf{q}$ （粒子并非放在格点上，而是采用更均匀的采样方式）以及拉格朗日微扰论一阶位移场 $\Psi_1(\mathbf{x}, z = 127)$ 通过 2LPTic 代码生成，并与 Quijote 数据集的初始条件保持完全一致^[17,18]。若已知某高红移 z_i 处被线性理论良好描述的一阶位移场 $\Psi_1(\mathbf{x}, z_i)$ ，则 ZA 估计红移 z 处的位移场和速度场为：

$$\Psi_{\text{ZA}}(\mathbf{x}, z) = \frac{D(z)}{D(z_i)} \Psi_1(\mathbf{x}, z_i), \quad (2.1)$$

$$\boldsymbol{v}_{\text{ZA}}(\boldsymbol{x}, z) = D(z)f(z)H(z)\frac{d\Psi_1(\boldsymbol{x}, z)}{dD(z)}, \quad (2.2)$$

其中 z_i 为初始红移，本文固定为 127。 $\boldsymbol{v}_{\text{ZA}}$ 为 ZA 速度场， $D(z)$ 为线性增长因子， $f(z) = d \ln D / d \ln a$ 为增长率， $a = 1/(1+z)$ 为尺度因子， $H(z)$ 为哈勃参数。

2.4 小尺度结构纠偏

我们使用神经网络对 ZA 基线进行纠偏，通过输入 ZA 基线预测残差来补全小尺度结构。当前工作流中启用两个残差网络，分别针对位移场和速度场，且速度场网络以位移场推理结果作为条件输入。以下分别介绍两者的网络架构、损失函数、训练及推理细节。

2.4.1 网络架构

位移场和速度场的残差神经网络均以 24^3 的三维局域窗口为基本样本。记条件输入为 $\boldsymbol{c}$ ，真实残差为 $\boldsymbol{r}$ ，生成器为 G ，则生成残差为 $\hat{\boldsymbol{r}} = G(\boldsymbol{c})$ 。两个任务采用相同的五层三维 U 形生成器和多尺度判别器主干，仅在条件输入通道数 C 上不同：位移网络取 $C = 3$ ，条件输入和残差输出均为三通道；速度网络取 $C = 6$ ，条件输入为 ZA 速度场与位移推理结果的拼接，残差输出仍为三通道速度场。判别器接收条件场与残差场的通道拼接，因此输入通道数为 $C + 3$ 。图 2.2 用一张通用结构图统一表示两个网络。

训练时，本文采用条件生成对抗网络 (GAN) 框架^[19]。GAN 由生成器 G 和判别器 D 组成： G 根据条件 $\boldsymbol{c}$ 产生残差样本 $\hat{\boldsymbol{r}}$ ， D 判断输入残差来自 N 体模拟还是来自生成器。两者交替优化，使生成残差不仅逐点接近真实残差，还在局域纹理、非线性团块和速度结构等统计特征上接近 N 体结果。

标准 GAN 的目标与 Jensen–Shannon 散度相关，在高维分布重叠较少时容易出现判别器饱和和生成器梯度变弱的问题。WGAN 将 D 解释为不输出概率的评论器，并用 Wasserstein-1 距离衡量真实残差分布 P_r 与生成残差分布 P_g 的差异^[20]。在给定条件 $\boldsymbol{c}$ 时，该距离可写为

$$W(P_r, P_g) = \sup_{\|D\|_L \leq 1} \mathbb{E}_{\boldsymbol{r} \sim P_r}[D(\boldsymbol{c}, \boldsymbol{r})] - \mathbb{E}_{\hat{\boldsymbol{r}} \sim P_g}[D(\boldsymbol{c}, \hat{\boldsymbol{r}})]. \quad (2.3)$$

其中 $W(P_r, P_g)$ 表示 Wasserstein-1 距离， P_r 和 P_g 分别表示真实残差和生成残差的条件分布， $\mathbb{E}$ 表示期望， $\|D\|_L \leq 1$ 表示评论器满足 1-Lipschitz 约束。Wasserstein 目标在两种分布支撑集相距较远时仍能提供连续的优化信号，因而适合本文的高维三维场残差训练。

WGAN-GP 进一步用梯度惩罚 (GP) 实现 1-Lipschitz 约束^[21]。它不采用早期

WGAN 的权重裁剪，而是在真实残差与生成残差之间的插值样本上约束评论器梯度范数接近 1，从而在保持判别器表达能力的同时提高对抗训练稳定性。本文选择 WGAN-GP，正是为了让网络稳定学习小尺度非线性残差的分布特征；具体损失形式将在下一小节给出。

2.4.1.1 位移场残差网络

设 N 体模拟给出的目标位移场为 Ψ_{ref} ，训练目标定义为


$$\Delta\Psi = \Psi_{\text{ref}} - \Psi_{\text{ZA}}. \quad (2.4)$$

生成器输入为 Ψ_{ZA} 的三通道局域窗口，输出为同尺寸的三通道残差位移场 $\Delta\Psi$ 。这种残差表征将 ZA 已保持较好的大尺度模式留给解析基准项，使神经网络专注于学习非线性演化导致的小尺度修正。

如图 2.2 上半部分所示，位移生成器采用五层三维 U 形编码器-解码器主干^[22]。对于位移场任务，生成器的条件输入通道数为 3，输出通道数也为 3。基础通道数设为 40，池化层数为 4。每个双卷积模块包含两层 $3 \times 3 \times 3$ 卷积，每层卷积后接批归一化和 ReLU 激活函数；每个下采样模块先进行 $2 \times 2 \times 2$ 最大池化，再执行双卷积模块。编码器空间分辨率依次为 $24^3 \rightarrow 12^3 \rightarrow 6^3 \rightarrow 3^3 \rightarrow 1^3$ ，通道数依次为 $40 \rightarrow 80 \rightarrow 160 \rightarrow 320 \rightarrow 320$ 。解码器使用三线性插值上采样，每一级将上采样特征与同分辨率的编码器特征按通道拼接，再通过双卷积模块融合；解码端通道数依次回落为 $160 \rightarrow 80 \rightarrow 40 \rightarrow 40$ 。最后的 $1 \times 1 \times 1$ 卷积做逐点通道投影，将 40 通道特征映射为三通道 $\Delta\Psi$ 。最终与 ZA 基准位移场 Ψ_{ZA} 通过滤波器结合得到最终位移场 Ψ_{final} ，再赋给每个粒子得到粒子位移。

位移场模型采用 WGAN-GP 训练框架^[21]，并使用多尺度判别器^[23]，其结构如图 2.2 下半部分所示。位移判别器的输入为条件场与残差场在通道维的拼接 $[\Psi_{\text{ZA}}, \Delta\Psi]$ ，对应 $C + 3 = 6$ 个通道；真实分支使用 $\Psi_{\text{ref}} - \Psi_{\text{ZA}}$ ，生成分支使用位移生成器输出的残差。每个子判别器以 64 个基准通道开始，由步长为 2 的 $3 \times 3 \times 3$ 卷积块构成，除第一层外使用实例归一化和 Leaky ReLU 激活函数。当前配置包含两个尺度：细尺度判别器使用 2 个卷积块，侧重局域纹理和高频残差；粗尺度判别器使用 3 个卷积块，约束更大感受野内的局部块级一致性。每个子判别器输出单通道真实性打分图。

位移生成器包含约 15.7M 个参数，两尺度判别器共包含约 1.4M 个参数；训练阶段生成器与判别器总参数量约为 17.1M。推理阶段仅使用生成器，参数量约 15.7M。



上半部分为五层三维 U 形生成器，输入为 24^3 局域窗口，经过编码、跳跃连接和解码后输出同尺寸残差场；图中 C 表示随任务替换的条件输入通道数，位移场取 $C = 3$ ，速度场取 $C = 6$ ，二者输出均为三通道残差场。下半部分为两尺度判别器，输入为条件场与三通道残差场的拼接，通道数为 $C + 3$ ；细分支使用两个步长为 2 的判别卷积块，粗分支使用三个步长为 2 的判别卷积块。

图 2.2 残差网络结构

2.4.1.2 速度场残差网络

速度场残差网络沿用图 2.2 中的同一套生成器和判别器主干，但条件输入与位移场不同。速度场网络不直接从单一 ZA 速度场预测最终速度，而是将 ZA 速度基准 $\mathbf{v}_{\text{ZA}}$ 与位移网络推理得到的最终位移场 Ψ_{final} 在通道维拼接，构造六通道条件张量：

$$\mathbf{c}_v = [\mathbf{v}_{\text{ZA}}, \Psi_{\text{final}}]. \quad (2.5)$$

速度网络的输出不是六通道条件场本身，而是三通道速度残差：

$$\Delta \mathbf{v} = \mathbf{v}_{\text{ref}} - \mathbf{v}_{\text{ZA}}. \quad (2.6)$$

这样，速度场网络可同时利用 ZA 速度场中的线性大尺度信息，以及位移场中已恢复的非线性密度结构信息。

如图 2.2 上半部分所示，速度生成器与位移生成器使用同一类五层三维 U 形网络，基础通道数也为 40。编码器分辨率同样为 $24^3 \rightarrow 12^3 \rightarrow 6^3 \rightarrow 3^3 \rightarrow 1^3$ ，通道数为 $40 \rightarrow 80 \rightarrow 160 \rightarrow 320 \rightarrow 320$ ；解码器经四级上采样恢复至 24^3 ，通道数为 $160 \rightarrow 80 \rightarrow 40 \rightarrow 40$ 。与位移生成器相比，速度生成器只在通道接口上变化：第一层卷积接收 $C = 6$ 个条件通道，最后的 $1 \times 1 \times 1$ 卷积仍输出三通道速度残差 $\Delta \mathbf{v}$ 。训练时还对输入条件和目标残差进行向量组共享标准化：速度条件三通道共享一组统计量，位移条件三通道共享一组统计量，目标速度残差三通道共享一组统计量；这些均值和标准差写入模型，推理阶段用于还原物理量纲。

速度场模型同样采用 WGAN-GP 和多尺度判别器，其结构如图 2.2 下半部分所示。速度判别器的输入为条件场与速度残差在通道维的拼接 $[\mathbf{v}_{\text{ZA}}, \Psi_{\text{final}}, \Delta \mathbf{v}]$ ，对应 $C + 3 = 9$ 个通道；训练时实际送入的是标准化后的张量。真实分支使用 $\mathbf{v}_{\text{ref}} - \mathbf{v}_{\text{ZA}}$ ，生成分支使用速度生成器输出的残差。判别器拓扑与位移场模型一致：每个子判别器以 64 个基准通道开始，由步长为 2 的 $3 \times 3 \times 3$ 卷积块构成，除第一层外使用实例归一化和 Leaky ReLU 激活函数。细尺度判别器使用 2 个卷积块约束局域速度残差形态，粗尺度判别器使用 3 个卷积块约束更大尺度的速度结构一致性。每个子判别器输出单通道打分图。

速度生成器包含约 15.7M 个参数，两尺度判别器共包含约 1.4M 个参数；训练阶段总参数量约为 17.1M，推理阶段仅使用生成器，参数量为 15.7M。

2.4.2 损失函数

2.4.2.1 位移场损失函数

位移场模型采用条件 WGAN-GP 目标，并在生成器端加入逐点 MSE、判别器特征匹配和多尺度平均 MSE。令 $\mathbf{c}_\Psi = \Psi_{\text{ZA}}$, $\mathbf{r}_\Psi = \Delta\Psi$, $\hat{\mathbf{r}}_\Psi = G_\Psi(\mathbf{c}_\Psi)$, 其中 G_Ψ 表示位移生成器。判别器包含细、粗两个尺度, 记尺度集合为 $\mathcal{M} = \{\text{fine}, \text{coarse}\}$, 第 m 个子判别器的局部块打分图为 $D_\Psi^{(m)}(\mathbf{c}_\Psi, \mathbf{r})$, $\langle \cdot \rangle$ 表示对打分图所有空间位置取平均。判别器损失为:

$$\mathcal{L}_{D_\Psi} = \frac{1}{|\mathcal{M}|} \sum_{m \in \mathcal{M}} \left[\mathbb{E} \left\langle D_\Psi^{(m)}(\mathbf{c}_\Psi, \hat{\mathbf{r}}_\Psi) \right\rangle - \mathbb{E} \left\langle D_\Psi^{(m)}(\mathbf{c}_\Psi, \mathbf{r}_\Psi) \right\rangle \right] + \lambda_{\text{gp}} \mathcal{L}_{\text{gp}, \Psi}, \quad (2.7)$$

其中梯度惩罚项为:

$$\mathcal{L}_{\text{gp}, \Psi} = \frac{1}{|\mathcal{M}|} \sum_{m \in \mathcal{M}} \mathbb{E}_{\tilde{\mathbf{r}}_\Psi} \left[\left(\left\| \nabla_{\tilde{\mathbf{r}}_\Psi} D_\Psi^{(m)}(\mathbf{c}_\Psi, \tilde{\mathbf{r}}_\Psi) \right\|_2 - 1 \right)^2 \right], \quad (2.8)$$

$\|\cdot\|_2$ 表示 L_2 范数, 且 $\tilde{\mathbf{r}}_\Psi = \epsilon \mathbf{r}_\Psi + (1 - \epsilon) \hat{\mathbf{r}}_\Psi$, $\epsilon \sim U(0, 1)$ 。梯度惩罚权重取 $\lambda_{\text{gp}} = 10$ 。

生成器损失为:

$$\mathcal{L}_{G_\Psi} = \mathcal{L}_{\text{adv}, \Psi} + 5 \mathcal{L}_{\text{pix}, \Psi} + 20 \mathcal{L}_{\text{fm}, \Psi} + \mathcal{L}_{\text{ms}, \Psi}. \quad (2.9)$$

其中对抗项和逐点项分别为

$$\mathcal{L}_{\text{adv}, \Psi} = -\frac{1}{|\mathcal{M}|} \sum_{m \in \mathcal{M}} \mathbb{E} \left\langle D_\Psi^{(m)}(\mathbf{c}_\Psi, \hat{\mathbf{r}}_\Psi) \right\rangle, \quad (2.10)$$

$$\mathcal{L}_{\text{pix}, \Psi} = \mathbb{E} \left[\frac{1}{3N_w^3} \left\| \hat{\mathbf{r}}_\Psi - \mathbf{r}_\Psi \right\|_2^2 \right], \quad N_w = 24. \quad (2.11)$$

特征匹配项 $\mathcal{L}_{\text{fm}, \Psi}$ 比较判别器中间层特征, 其作用是引导生成器生成更真实的局部结构。多尺度项 $\mathcal{L}_{\text{ms}, \Psi}$ 使用核宽集合 $\mathcal{S} = \{1, 2, 4, 8\}$ 进行多尺度平均约束, 等效于增加了对位移场的空间梯度的约束。

2.4.2.2 速度场损失函数

速度场模型同样采用条件 WGAN-GP, 损失在标准化后的速度残差张量上计算。令标准化条件为 $\mathbf{c}_v = [\mathbf{v}_{\text{ZA}}, \Psi_{\text{final}}]$, 标准化真实残差为 $\mathbf{r}_v$, 生成器输出为 $\hat{\mathbf{r}}_v = G_v(\mathbf{c}_v)$, 其中 G_v 表示速度生成器。判别器损失形式与位移场类似, 梯度惩罚权重亦为 $\lambda_{\text{gp}} = 10$ 。生成器损失为:

$$\mathcal{L}_{G_v} = \mathcal{L}_{\text{adv}, v} + 5 \mathcal{L}_{\text{pix}, v} + 20 \mathcal{L}_{\text{fm}, v} + \mathcal{L}_{\text{ms}, v}. \quad (2.12)$$

各分量定义与位移场对应项类似, 仅替换为速度场相关量。

2.4.3 模型训练

训练样本来自 Quijote 模拟中的 32 个实现，其中 16 个用于位移场训练，另外 16 个用于速度场训练。速度场训练时需要推理得到的位移场作为条件输入，采用与位移场不同的模拟集可避免输入来自训练集。训练样本块以周期窗口方式从全盒子中划分：有效块长为 20，边界填充为 2，模型实际输入窗口为 24^3 ，回填时只使用中心 20^3 有效区域。每个 256^3 网格在三轴上以步长 20 周期切块，得到 $13^3 = 2197$ 个训练块。

位移训练中，输入来自 Ψ_{ZA} ，目标来自 $\Psi_{\text{ref}} - \Psi_{\text{ZA}}$ ，不做旋转增强；速度训练中，先由当前位移模型推理得到 Ψ_{final} ，输入来自 $[\mathbf{v}_{\text{ZA}}, \Psi_{\text{final}}]$ ，目标来自 $\mathbf{v}_{\text{ref}} - \mathbf{v}_{\text{ZA}}$ 。速度训练时对条件场中的两个三通道向量组和目标速度残差同步随机施加 24 个保向立方体旋转之一，以降低可能存在的训练集导致的神经网络对不同通道的偏好，尽量保证神经网络的各向同性。

位移模型训练 1000 轮，批量大小 512；速度模型训练 1000 轮，批量大小 64。两者均使用 AdamW 优化器，生成器和判别器学习率均为 10^{-4} ，采用余弦退火调度至 10^{-7} 。判别器每个小批量更新一次。速度模型额外保存输入条件和速度残差的向量组共享均值与标准差，用于推理阶段的标准化与反标准化。

2.4.4 模型推理

位移场推理：首先由 ZA 得到全盒子的 Ψ_{ZA} ，按三个方向步长 20 切成 13^3 个 24^3 窗口送入位移生成器。输出残差经每边 2 像素剪切得到 20^3 有效区域，回填全盒子后，对预测残差 $\Delta\Psi_{\text{pred}}$ 逐分量施加傅里叶空间高通滤波：

$$\begin{aligned}\Psi_{\text{final}}(\mathbf{x}) &= \Psi_{\text{ZA}}(\mathbf{x}) + \mathcal{F}^{-1} [W_{\text{HP}}(k) \mathcal{F} [\Delta\Psi_{\text{pred}}](\mathbf{k})](\mathbf{x}), \\ W_{\text{HP}}(k) &= \frac{1}{1 + \exp [-(k - k_{\text{cut}})/\Delta k]}, \quad k = |\mathbf{k}|, \\ k_{\text{cut}} &= 0.02, \quad \Delta k = 0.01,\end{aligned}\tag{2.13}$$

其中 $\mathcal{F}$ 表示傅里叶变换， $\mathcal{F}^{-1}$ 表示逆傅里叶变换。因为神经网络输入输出体积较小，只能保证较小尺度的信息，该滤波避免回填后的网络残差改写 ZA 已保留的大尺度模式。

速度场推理：在位移推理之后进行。先构造 ZA 速度场 $\mathbf{v}_{\text{ZA}}$ ，与 Ψ_{final} 拼接成 6 通道条件场，按相同方式切块送入速度生成器。推理得到的残差经剪切回填。为消除训练导致的坐标轴不一致性，启用旋转平均：对原始方向和两个循环坐标轴方向分别旋转完整条件场及其向量分量，推理后旋回原坐标系，对三次结果取平

均得到 $\Delta \mathbf{v}_{\text{pred}}$ 。当前速度推理不施加高通滤波，最终速度场为：

$$\mathbf{v}_{\text{final}}(\mathbf{x}) = \mathbf{v}_{\text{ZA}}(\mathbf{x}) + \Delta \mathbf{v}_{\text{pred}}(\mathbf{x}). \quad (2.14)$$


由于位移和速度网络仅依赖局域窗口和周期拼接，该推理过程可直接扩展到更大体积的模拟盒子以满足下一代大规模结构模拟的需求。

第 3 章 研究成果

本章从暗物质密度场和速度场两个方面评估本文快速模拟流程的表现。由于维里化的存在，最小尺度的结构不能被模拟逐点准确预测，N 体模拟也并非在逐点意义上完全可复现，故本文主要关注小尺度结构的统计特征。密度场部分依次考察切片视觉效果、过密度残差概率密度函数、功率谱、双谱以及功率谱协方差矩阵；速度场部分考察速度模切片以及速度散度、旋度、速度模和速度分量的功率谱。除特别说明外，统计量均以 Quijote 低精度 N 体模拟为参考^[17]，并将新流程与 ZA、2LPT 和 ALPT 等微扰论基准进行比较。

3.1 暗物质场单点统计

首先比较过密度场 $\delta(\mathbf{x}) = \rho(\mathbf{x})/\bar{\rho} - 1$ 的单点统计和切片形态。其中 $\rho(\mathbf{x})$ 是位置 $\mathbf{x}$ 处的暗物质密度， $\bar{\rho}$ 是全模拟盒子的平均密度。图 3.1 展示了一个模拟实现的过密度切片。N 体模拟中可以看到清晰的丝状结构、高密度团块和空洞区域；ZA 基准能够保留大尺度结构的位置，但小尺度团块明显更弥散，高密度峰值也更平滑。新流程在整体结构位置上与 ZA 保持一致，同时显著增强了丝状结构和团块的紧致程度，在视觉上更接近 N 体模拟。




左：N 体模拟参考结果，显示非线性演化后的团块、丝状结构和空洞；中：ZA 基准结果，小尺度结构更平滑、团块更弥散；右：新流程结果，在保留大尺度结构的同时恢复出更紧凑的小尺度团块和更丰富的细节。

图 3.1 过密度切片比较

为进一步量化单点恢复效果，我们比较不同方法相对 N 体参考的过密度残差 $\delta - \delta_{\text{ref}}$ 的概率密度函数。图 3.2 显示，ZA、2LPT 和 ALPT 的残差分布具有较宽的尾部，说明这些微扰论方法在高密度团块和低密度空洞处仍存在较大的逐点偏差。

新流程的残差分布在 $\delta - \delta_{\text{ref}} = 0$ 附近有更高、更尖锐的峰值，并且在主要残差范围内明显更窄，表明神经网络纠偏后过密度场在单点统计上更接近 N 体结果。少数极端残差仍然存在，说明最非线性的局域结构并未被逐点完全恢复，但总体误差分布已经显著收缩。



曲线统计了 16 个模拟实现与 N 体模拟的过密度残差的概率密度分布，阴影表示不同实现的 1σ 散布，散布很小；ZA、2LPT 和 ALPT 的残差分布尾部更宽，新流程的残差更集中于 0 附近，说明单点统计恢复更接近 N 体结果。

图 3.2 过密度残差概率密度函数比较

3.2 暗物质场两点统计

两点统计用物质功率谱 $P(k)$ 表征，定义为


$$P(k) = \langle |\delta(\mathbf{k})|^2 \rangle, \quad (3.1)$$

其中 $\delta(\mathbf{k})$ 是过密度场的傅里叶变换， $\mathbf{k}$ 是波矢， $k = |\mathbf{k}|$ 是波数； $\langle \cdot \rangle$ 表示对同一 k 壳层内所有傅里叶模式取平均。由于模拟场的离散化，功率谱在高波数端会受到采样噪声影响，由 Nyquist 频率限制。在本文环境中，Nyquist 频率对应波数为 $k_{\text{Nyquist}} = \pi N_{\text{grid}}/L = 0.804 h \text{ Mpc}^{-1}$ ，其中 $N_{\text{grid}} = 256$ 是网格数， $L = 1 h^{-1} \text{ Gpc}$ 是模拟盒子边长， k_{Nyquist} 之上的波数无法可靠估计。图 3.3 给出了共 16 个模拟实现的功率谱比值 P/P_{ref} 。在大尺度低波数区域，各方法都接近 N 体参考结果，这与微扰论在弱非线性尺度上有效的预期一致。随着波数增大，ZA、2LPT 和 ALPT 的功率谱比值逐渐低于 1，说明这些方法在小尺度上系统性低估密度涨落功率。

相比之下，新流程在图示波数范围内始终保持在 1 附近，仅在最高波数端出现轻微下降。这说明残差网络有效补偿了 ZA 基准缺失的小尺度非线性功率，并且

没有明显破坏大尺度模式。结合图 3.1 的视觉结果可以看出，功率谱上的改进主要来自高密度团块和细丝结构的恢复。

虽然 TUNeS 方法使用了 2 倍于当前的粒子分辨率，但其在红移 0 的 $k \lesssim 0.8 h \text{Mpc}^{-1}$ 区间有时会超过 6% 的相对误差^[16]；本文方法在红移 0 的表现始终处于 4% 以内的误差水平。这表明本文架构在小尺度结构恢复方面具有更稳定和更高的准确性，尤其是在非线性演化较强的区域。



展示了 16 个模拟实现与 N 体模拟的功率谱比值，曲线为不同实现的均值，阴影为 1σ 散布，散布很小；ZA、2LPT 和 ALPT 在小尺度逐渐低估功率，而新流程在接近 Nyquist 波数前整体保持在 1 附近，最大相对误差为 4%。

图 3.3 暗物质功率谱比值

3.3 暗物质场三点统计


三点统计进一步检验非高斯结构的恢复情况。物质双谱 $B(k_1, k_2, k_3)$ 定义为

$$B(k_1, k_2, k_3) = \langle \delta(\mathbf{k}_1) \delta(\mathbf{k}_2) \delta(\mathbf{k}_3) \rangle, \quad (3.2)$$

其中三个波矢满足构成矢量三角形的条件 $\mathbf{k}_1 + \mathbf{k}_2 + \mathbf{k}_3 = 0$ ， k_1, k_2, k_3 分别是三个波矢的模； $\langle \cdot \rangle$ 表示对满足该三角形构型的傅里叶模式组合取平均。在比较时，我们固定其中两个波数 k_1 和 k_2 ，并将两波矢夹角 θ 作为横轴。

图 3.4 比较了六种三角形构型下的双谱比值 B/B_{ref} 。在所有构型中，ZA、2LPT 和 ALPT 的比值普遍低于 1，且偏差随 k_1 和 k_2 增大而加重，说明微扰论方法不仅低估小尺度两点功率，也未能充分恢复非线性结构引入的三点关联。特别是在 $k_1 = k_2 = 0.40 h \text{Mpc}^{-1}$ 等更小尺度构型中，微扰论基准的双谱只达到 N 体参考的一小部分。

新流程在六个构型中均显著接近比值 1，尤其在低、中等波数构型下基本保持在 N 体参考附近。在较高波数构型中，新流程仍有轻微低估，但偏差远小于 ZA、2LPT 和 ALPT。这表明残差网络不仅恢复了功率谱幅度，也较好地恢复了由非线性引力演化带来的高阶相位耦合。




展示了共 16 个模拟实现与 N 体模拟在不同构型下的双谱比值，横轴为两波矢夹角 θ 。红色实线的新流程在各构型中更接近 1，而微扰论基准在非线性尺度上的双谱幅度偏低。

图 3.4 暗物质双谱比值

3.4 暗物质功率谱协方差矩阵

除均值统计外，协方差矩阵也是宇宙学参数推断中必须准确估计的量。这里使用共 240 个模拟实现估计暗物质功率谱协方差矩阵，并比较新流程与 N 体参考结果的差异。图 3.5 左上和右上分别给出 N 体参考与新流程的 $\log_{10} |\text{Cov}(P(k))|$ 。两者在整体矩阵形态、低波数与高波数之间的相关结构以及对角线主结构上较为相似，说明新流程能够较好地保留不同尺度功率谱涨落之间的相关性。

更细致地看，图 3.5 左下显示新流程相对 N 体参考的协方差逐元差异在较大 k 区域整体偏负；右下的对角元比值也显示，新流程在小尺度上的方差低于 N 体参考。尽管如此，新流程的协方差对角元仍明显高于 ZA、2LPT 和 ALPT，这说明神经网络纠偏显著改善了快速模拟对样本方差的恢复。当前协方差估计只使用 240 个模拟实现，样本数量仍偏少，因此矩阵元素会受到较强采样噪声影响；后续需要用更多模拟进一步验证小尺度协方差低估是否为稳定系统偏差。




协方差矩阵由 240 个模拟实现估计得到。左上：N 体参考功率谱协方差矩阵的 $\log_{10} |\text{Cov}_{\text{ref}}(P(k))|$ ；右上：新流程功率谱协方差矩阵的 $\log_{10} |\text{Cov}_{\text{final}}(P(k))|$ ；左下：新流程相对 N 体参考协方差矩阵的逐元相对差异；右下：ZA、ALPT、2LPT 和新流程的协方差对角元相对 N 体参考的比值。

图 3.5 暗物质功率谱协方差矩阵

3.5 速度场视觉展示

速度场对红移空间畸变和运动学 SZ 效应等探针非常重要，因此本文进一步评估速度场恢复效果。图 3.6 展示了一个模拟实现的速度模 $|\mathbf{v}|$ 切片。N 体模拟中速度场包含明显的小尺度高速度结构，这些结构通常与非线性团块和局域塌缩区域相关。ZA 基准速度场主要反映线性大尺度流动，图像更平滑，缺少许多局域高速度峰值。

新流程生成的速度场在整体空间分布上与 N 体结果更相似，并恢复出更多与高密度结构相关的小尺度速度特征。右下角残差图显示，较大的速度残差主要集中在高速度团块附近，说明维里化区域和强非线性塌缩区域仍是速度恢复中最困难的部分。总体而言，速度残差网络能够在 ZA 大尺度速度基准上补充非线性细节，但逐点速度场的恢复难度高于密度场。



左上：N 体模拟参考速度模 $|v|$ ，包含非线性小尺度速度结构；右上：ZA 基准速度模，整体更平滑，小尺度高速度团块不足；左下：新流程速度模，在小尺度结构上更接近 N 体模拟；右下：N 体模拟与新流程速度场之差的残差模 $|\Delta v|$ ，亮区对应尚未完全恢复的小尺度速度结构。

图 3.6 速度模切片比较


3.6 速度场两点统计

最后比较速度场的两点统计。图 3.7 分别给出速度散度、速度旋度模、速度模以及三个速度分量的功率谱比值。速度散度主要反映大尺度汇聚和发散运动。ZA 在中等波数处出现一定过冲，并在高波数端快速下降；新流程在低、中波数范围内更接近 N 体参考，在高波数端虽然仍低于 1，但整体偏差小于 ZA，说明速度残差网络改善了速度场中与大尺度结构演化相关的可压缩部分。

旋度模功率谱体现非线性演化和维里化运动产生的涡旋成分。由于 ZA 属于线性势流近似，不能产生旋度功率；新流程能够生成非零旋度信号，并在小尺度上恢复出一部分 N 体模拟中的旋度结构。不过图中红线仍明显低于 1，说明当前模型对维里化区域的速度旋度恢复仍不充分。速度模功率谱也表现出类似趋势：新流程相较 ZA 有明显提升，但在全波数范围内仍系统性低估 N 体速度模功率。

三个速度分量的功率谱比值显示，新流程在低波数处基本保持与 N 体参考一

致，高波数端逐渐下降；相比 ZA，速度残差网络延缓了小尺度功率损失，在大尺度上也有所改善。综合来看，速度场结果证明本文方法能够改善 ZA 速度基准，但速度场的小尺度随机运动和旋度结构比密度场更难学习，仍是后续模型优化的重点。



第 32–47 个模拟实现的速度场功率谱以 N 体模拟为参考。左上：速度散度功率谱比值 $P_{\theta\theta}/P_{\theta\theta,\text{ref}}$ ；右上：速度旋度模功率谱比值 $P_{|\nabla\times v|}/P_{|\nabla\times v|,\text{ref}}$ ；左下：速度模功率谱比值 $P_{|v|}/P_{|v|,\text{ref}}$ ；右下：三个速度分量功率谱比值 $P_{v_i v_j}/P_{v_i v_j,\text{ref}}$ 。虚线为 ZA，实线为新流程，阴影为不同实现的 1σ 散布。

图 3.7 速度场功率谱比值

3.7 运行时间与内存占用

除统计精度外，快速模拟方法还需要在实际生成任务中保持较低的计算开销。本文在 NVIDIA A100 40GB GPU 上进行模型训练和推理，记录训练阶段的峰值显存和内存占用，并测量从读取初始粒子位置 $\mathbf{q}$ 与一阶位移场 $\Psi_1(\mathbf{x}, z = 127)$ 到完整输出位移场和速度场的端到端运行时间，结果见表 3.1。

表 3.1 运行时间与内存占用

指标	对象或阶段	数值
GPU 峰值显存	位移场模型单 epoch 训练	~ 20GB
GPU 峰值显存	速度场模型单 epoch 训练	~ 3GB
CPU 峰值内存	速度场模型单 epoch 训练	~ 39GB
运行时间	读取 $\mathbf{q}$ 、 $\Psi_1(\mathbf{x}, z = 127)$ 至输出位移场	~ 16s
运行时间	位移场输出后至输出速度场	~ 37s
运行时间	完整流程总计	~ 54s

可以看到，两个网络的训练显存峰值均能放入单张 A100 40GB GPU，其中位移场模型显存占用更高，而速度场模型的 GPU 显存峰值较低。速度场测试中的 CPU 峰值内存较高，主要来自完整训练集一次性加载，而不是速度生成器本身的显存需求。推理阶段从初始条件读取到位移场输出仅需 ~ 16s，继续生成速度场后总耗时为 ~ 54s，说明该流程能够在约一分钟内完成一个 $1 (h^{-1}\text{Gpc})^3$ 体积、 256^3 粒子数模拟实现的位移场和速度场生成，具有较明显的速度优势。

第 4 章 结论与展望

本文面向宇宙学协方差矩阵估计和多探针联合分析对快速模拟的需求，提出了一种基于尺度分离思想的数据驱动快速模拟流程。该流程使用 Zel'dovich 近似生成位移场和速度场的大尺度基准，再通过两个三维 WGAN-GP 残差网络分别补全位移场和速度场的小尺度非线性结构。位移场网络直接学习 N 体模拟相对 ZA 的位移残差；速度场网络则以 ZA 速度场和位移网络推理得到的最终位移场作为联合条件，学习速度残差。通过分块推理、高通滤波和旋转平均，该流程在保持快速生成优势的同时，能够稳定扩展至同分辨率下更大体积的模拟任务。

在 Quijote N 体模拟上的验证表明，本文方法能够显著改善传统微扰论快速模拟在小尺度上的不足。对于暗物质密度场，新流程在视觉切片中恢复出更紧凑的团块和更清晰的丝状结构；其过密度残差分布更集中于零附近，功率谱和双谱也比 ZA、2LPT 和 ALPT 更接近 N 体参考结果。这说明残差网络不仅补偿了小尺度功率，也恢复了一部分由非线性演化产生的高阶相位耦合。功率谱协方差矩阵的结果进一步显示，新流程相较于原有方法能够更好地保留不同尺度功率谱涨落之间的相关结构，但小尺度对角方差仍有低估，且当前协方差估计受到有限模拟样本数的影响。

速度场结果表明，使用位移场推理结果作为条件输入能够为速度残差网络提供有效的非线性结构信息。新流程相较 ZA 恢复了更多小尺度速度结构，甚至大尺度上也有所改善，并在速度散度功率谱和速度分量功率谱上取得明显改进。同时，性能测试显示该流程从初始条件读取到完整输出位移场和速度场约需 54s，能够在保持统计改进的同时维持较快的生成速度。不过，速度场比密度场更难逐点恢复，尤其是在维里化区域以及旋度成分上，当前模型仍存在系统性低估。这说明仅依赖局域残差学习仍不足以完全刻画小尺度随机运动。

后续工作可从三个方面继续改进。首先，可使用更多模拟实现训练和验证模型，以降低协方差矩阵估计中的采样噪声，并更可靠地判断小尺度方差低估是否为稳定偏差。其次，可针对速度场引入更适合涡旋结构的损失函数或物理约束，提升旋度和维里化速度的恢复能力。最后，可在更大体积的模拟盒子上测试分块推理流程，并系统评估生成速度、内存占用和可扩展性，从而进一步检验该方法在实际宇宙学模拟生产中的应用价值。

参考文献

- [1] ADAME A G, et al. DESI 2024 V: Full-shape galaxy clustering from galaxies and quasars [J/OL]. *Journal of Cosmology and Astroparticle Physics*, 2025, 2025(02): 021. DOI: 10.1088/1475-7516/2025/02/021.
- [2] Planck Collaboration, et al. Planck 2015 results. XIII. cosmological parameters[J/OL]. *Astronomy and Astrophysics*, 2016, 594: A13. DOI: 10.1051/0004-6361/201525830.
- [3] Euclid Collaboration, et al. Euclid preparation. VII. forecast validation for Euclid cosmological probes[J/OL]. *Astronomy and Astrophysics*, 2020, 642: A191. DOI: 10.1051/0004-6361/202038071.
- [4] KITCHING T D, HEAVENS A F, DAS S. 3D weak gravitational lensing of the CMB and galaxies[J/OL]. *Monthly Notices of the Royal Astronomical Society*, 2015, 449(3): 2205-2214. DOI: 10.1093/mnras/stv334.
- [5] SPRINGEL V, PAKMOR R, ZIER O, et al. Simulating cosmic structure formation with the GADGET-4 code[J/OL]. *Monthly Notices of the Royal Astronomical Society*, 2021, 506(2): 2871-2949. DOI: 10.1093/mnras/stab1855.
- [6] KITAURA F S, HESS S. Cosmological structure formation with augmented lagrangian perturbation theory[J/OL]. *Monthly Notices of the Royal Astronomical Society: Letters*, 2013, 435(1): L78-L82. DOI: 10.1093/mnrasl/slt101.
- [7] KITAURA F S, YEPES G, PRADA F. Modelling baryon acoustic oscillations with perturbation theory and stochastic halo biasing[J/OL]. *Monthly Notices of the Royal Astronomical Society: Letters*, 2014, 439(1): L21-L25. DOI: 10.1093/mnrasl/slt172.
- [8] CHUANG C H, KITAURA F S, PRADA F, et al. EZmocks: Extending the Zel'dovich approximation to generate mock galaxy catalogues with accurate clustering statistics[J/OL]. *Monthly Notices of the Royal Astronomical Society*, 2015, 446(3): 2621-2628. DOI: 10.1093/mnras/stu2301.
- [9] JEONG D, KOMATSU E. Perturbation theory reloaded: Analytical calculation of non-linearity in baryonic oscillations in the real space matter power spectrum[J/OL]. *The Astrophysical Journal*, 2006, 651(2): 619-626. DOI: 10.1086/507781.
- [10] TARUYA A, NISHIMICHI T, JEONG D. Grid-based calculation for perturbation theory of large-scale structure[J/OL]. *Physical Review D*, 2018, 98(10): 103532. DOI: 10.1103/PhysRevD.98.103532.
- [11] CARRASCO J J M, FOREMAN S, GREEN D, et al. The effective field theory of large scale structures at two loops[J/OL]. *Journal of Cosmology and Astroparticle Physics*, 2014, 2014(07): 057. DOI: 10.1088/1475-7516/2014/07/057.
- [12] HE S, LI Y, FENG Y, et al. Learning to predict the cosmological structure formation[J/OL]. *Proceedings of the National Academy of Sciences*, 2019, 116(28): 13825-13832. DOI: 10.1073/pnas.1821458116.

- [13] OLIVEIRA R A D, LI Y, VILLAESCUSA-NAVARRO F, et al. Fast and accurate non-linear predictions of universes with deep learning[A/OL]. 2020. DOI: 10.48550/arXiv.2012.00240.
- [14] JAMIESON D, LI Y, DE OLIVEIRA R A, et al. Field-level neural network emulator for cosmological N-body simulations[J/OL]. The Astrophysical Journal, 2023, 952(2): 145. DOI: 10.3847/1538-4357/acdb6c.
- [15] JAMIESON D, LI Y, VILLAESCUSA-NAVARRO F, et al. Field-level emulation of cosmic structure formation with cosmology and redshift dependence[A/OL]. 2024. DOI: 10.48550/arXiv.2408.07699.
- [16] KANG Y, HU B, LI D, et al. TUNeS: Neural emulation of large-scale structure across redshifts [A/OL]. 2026. DOI: 10.48550/arXiv.2603.18165.
- [17] VILLAESCUSA-NAVARRO F, HAHN C, MASSARA E, et al. The Quijote simulations[J/OL]. The Astrophysical Journal Supplement Series, 2020, 250(1): 2. DOI: 10.3847/1538-4365/ab9d82.
- [18] JENKINS A. Second-order lagrangian perturbation theory initial conditions for resimulations [J/OL]. Monthly Notices of the Royal Astronomical Society, 2010, 403(4): 1859-1872. DOI: 10.1111/j.1365-2966.2010.16259.x.
- [19] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial networks: arXiv:1406.2661[M/OL]. arXiv, 2014[2026-06-01]. <http://arxiv.org/abs/1406.2661>. DOI: 10.48550/arXiv.1406.2661.
- [20] ARJOVSKY M, CHINTALA S, BOTTOU L. Wasserstein generative adversarial networks [C/OL]/ICML'17: Proceedings of the 34th International Conference on Machine Learning - Volume 70. Sydney, NSW, Australia: JMLR.org, 2017: 214-223[2026-06-01]. <https://dl.acm.org/doi/10.5555/3305381.3305404>.
- [21] GULRAJANI I, AHMED F, ARJOVSKY M, et al. Improved training of wasserstein GANs [C/OL]/NIPS'17: Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2017: 5769-5779[2026-06-01]. <https://dl.acm.org/doi/10.5555/3295222.3295327>.
- [22] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C/OL]/NAVAB N, HORNEGGER J, WELLS W M, et al. Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. Cham: Springer International Publishing, 2015: 234-241. DOI: 10.1007/978-3-319-24574-4_28.
- [23] WANG T C, LIU M Y, ZHU J Y, et al. High-resolution image synthesis and semantic manipulation with conditional GANs[C/OL]/2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 8798-8807[2026-06-01]. <https://ieeexplore.ieee.org/document/8579015/>. DOI: 10.1109/CVPR.2018.00917.

致 谢

衷心感谢指导教师赵成副教授在课题选题、研究方法和论文写作过程中给予的指导与帮助。老师严谨的科研态度和清晰的学术思路使我受益匪浅。

感谢在课题研究和论文写作过程中给予讨论、建议和支持的老师、同学与朋友。相关交流帮助我不断完善对宇宙学快速模拟问题的理解，也推动了本文方法和实验结果的改进。

感谢 DESI 项目和 NERSC 中心提供的计算资源，使得本文的模拟训练和验证得以顺利进行。

感谢家人在学习和生活中给予的理解与支持。

声 明

本人郑重声明：所呈交的综合论文训练论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名： 刘以恒 日 期： 2026.6.22

综合论文训练记录表

学生姓名	刘以恒	学号	2021013385	班级	数理-数理 1
论文题目	数据驱动的宇宙学快速模拟方法				
主要内容以及进度安排	主要内容：现有的生成宇宙学快速模拟的方法达不到下一代星系巡天项目需求，我尝试使用一种新的数据驱动的方法生成宇宙学快速模拟。具体方法为：将宇宙学模拟分为大、中、小多个尺度，分别用不同方法进行模拟处理。对于大尺度，我们使用微扰论直接得到；对于中等尺度，我们使用初始过密度泛函的线性组合进行拟合，得到最佳拟合结果；对于小尺度，我们使用机器学习或者概率模型进行拟合。最后将不同尺度拟合结果进行结合，由此生成更精确的宇宙学快速模拟。 进度安排：我计划在三月之前完成对于大、中尺度的拟合并得到更好的拟合结果，在中期答辩时初步完成整个流程，在最终答辩前完成最终流程的调试，期待能够生成比目前使用的宇宙学快速模拟更加精确的模拟结果。 指导教师签字：_____ 考核组组长签字：_____ 年 月 日				
中期考核意见	同意通过。 考核组组长签字：_____ 2026 年 4 月 3 日				

指导教师评语	本论文旨在结合微扰论和人工智能方法,构建适用于多探针宇宙学分析的快速数值模拟方法,对观测宇宙学领域的理论建模和误差分析具有重要意义。论文创新性地采用了多尺度分解的方法,仅使用少量计算资源就可得到与高精度N体模拟非常接近的暗物质成团性统计,有广泛的应用前景。论文的背景文献调研充分全面,研究方案周密严谨,最终结果具有较高科学价值。本论文内容完整,书写规范,是一篇优秀的学士学位论文。 指导教师签字: <u>李昕宇</u> 2026年 6月 9日
评阅教师评语	本论文开发了新的宇宙学模拟方法。结合AI的新技术,对功率谱和双谱估计得到了很好的结果。写作通顺,行文规范。 评阅教师签字: <u>李昕宇</u> 2026年 6月 9日
答辩小组评语	该生答辩陈述凝练,答题思路清晰,表达准确。论文结构规整,选题有价值,工作量饱满,同意答辩通过。 答辩小组组长签字: <u>李昕宇</u> 2026年 6月 11日

总成绩: A-
教学负责人签字: 张定

2026年 6月 12日